

第五章 特征值的估计及对称矩阵的极性

5.1 特征值的估计

1. 特征值界的估计

•定理 1: 设 $A \in R^{n \times n}$, λ 为 A 的任意特征值, 则有 $|\operatorname{Im}(\lambda)| \leq M \sqrt{\frac{n(n-1)}{2}}$, 其中, $M = \max_{1 \leq i, j \leq n} \left| \frac{a_{ij} - a_{ji}}{2} \right|$

证明: 设 x 为 A 的属于特征值 λ 的单位特征向量, 即 $Ax = \lambda x$, $x^H x = 1$, 则

$$\lambda = x^H A x \rightarrow \bar{\lambda} = \overline{(x^H A x)} = (x^H A x)^H = x^H A^H x$$

$$\lambda - \bar{\lambda} = 2j \operatorname{Im}(\lambda) = x^H (A - A^H) x = x^H (A - A^T) x$$

将 x 写成 $x = [\xi_1, \xi_2, \dots, \xi_n]^T$

$$x^H (A - A^T) x = \sum_{i=1}^n \sum_{j=1}^n \bar{\xi}_i (a_{ij} - a_{ji}) \xi_j$$

$$\begin{aligned} 2|\operatorname{Im}(\lambda)| &= \left| \sum_{i=1}^n \sum_{j=1}^n \bar{\xi}_i (a_{ij} - a_{ji}) \xi_j \right| \\ &\leq \sum_{i=1}^n \sum_{j=1}^n |\bar{\xi}_i (a_{ij} - a_{ji}) \xi_j| \\ &= \sum_{i,j=1}^n |\xi_i \xi_j| |a_{ij} - a_{ji}| \quad (\sum' \text{ 表示不含 } i=j) \end{aligned}$$

$$\leq 2M \sum_{i,j=1}^n |\xi_i \xi_j|$$

$$\begin{aligned} |\operatorname{Im}(\lambda)|^2 &\leq M^2 \left(\sum_{i,j=1}^n |\xi_i \xi_j| \right)^2 \\ &\leq M^2 n(n-1) \sum_{i,j=1}^n |\xi_i \xi_j|^2 \\ &= M^2 n(n-1) \sum_{i,j=1}^n |\xi_i|^2 |\xi_j|^2 \end{aligned}$$

$$\begin{aligned} \sum_{i,j=1}^n |\xi_i|^2 |\xi_j|^2 &= \sum_{i,j=1}^n |\xi_i|^2 |\xi_j|^2 - \sum_{i=1}^n |\xi_i|^4 \leq \sum_{i=1}^n |\xi_i|^2 - \sum_{i=1}^n |\xi_i|^4 \\ &= \sum_{i=1}^n |\xi_i|^2 (1 - |\xi_i|^2) \end{aligned}$$

$$\begin{aligned} \text{不妨写为: } &= |\xi_1|^2 (1 - |\xi_1|^2) + |\xi_2|^2 (1 - |\xi_2|^2) + \sum_{i=3}^n |\xi_i|^2 (1 - |\xi_i|^2) \\ &\leq \left(\frac{|\xi_1|^2 + (1 - |\xi_1|^2)}{2} \right)^2 + \left(\frac{|\xi_2|^2 + (1 - |\xi_2|^2)}{2} \right)^2 + \sum_{i=3}^n |\xi_i|^2 (1 - |\xi_i|^2) \\ &\leq \frac{1}{2} \end{aligned}$$

取等号的条件为 $|\xi_1|^2 = |\xi_2|^2 = \frac{1}{2}$, 但 $\|x\|^2 = 1$, 所以其它 $|\xi_i|^2 = 0$

$$\therefore |\operatorname{Im}(\lambda)| \leq M \sqrt{\frac{n(n-1)}{2}}$$

•定理 2: 设 $A \in C^{n \times n}$, λ 为 A 的任意特征值, 则有:

$$|\lambda| \leq \|A\|_{m_\infty} = n \cdot \max_{1 \leq i, j \leq n} |a_{ij}|$$

$$|\operatorname{Re}(\lambda)| \leq \frac{1}{2} \|A + A^H\|_{m_\infty} = n \cdot \max_{1 \leq i, j \leq n} |a_{ij} + \overline{a_{ji}}|$$

$$|\operatorname{Im}(\lambda)| \leq \frac{1}{2} \|A - A^H\|_{m_\infty} = n \cdot \max_{1 \leq i, j \leq n} |a_{ij} - \overline{a_{ji}}|$$

例 5.1 估计矩阵 $A = \begin{bmatrix} 1 & -0.8 \\ 0.5 & 0 \end{bmatrix}$ 的特征值的上界.

解 应用定理 5.2, 可得 $|\lambda| \leq 2$, $|\operatorname{Re}(\lambda)| \leq 2$, $|\operatorname{Im}(\lambda)| \leq$

1.3. 应用定理 5.1 估计 $\operatorname{Im}(\lambda)$, 有

$$M = 0.65, \quad |\operatorname{Im}(\lambda)| \leq M \sqrt{\frac{2(2-1)}{2}} = 0.65$$

实际上, A 的两个特征值是 $\lambda_{1,2} = \frac{1}{2}(1 \pm j \sqrt{0.6})$, 从而 $|\lambda_{1,2}| = 0.632456$, $|\operatorname{Re}(\lambda_{1,2})| = 0.5$, $|\operatorname{Im}(\lambda_{1,2})| = 0.387298$.

例 5.1 表明, 在估计实矩阵的特征值的虚部上界时, 定理 5.1 的结果优于定理 5.2 的结果.

2. 盖尔圆法

•定义: 设 $A = (a_{ij})_{n \times n} \in C^{n \times n}$, 称由不等式 $|z - a_{ii}| \leq R_i$ 在复平面上确定的区域为矩阵 A 的第 i 个盖尔圆, 用 G_i 表示, 其中:

$$R_i = R_i(A) = \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|$$

称为盖尔圆 G_i 的半径.

•定理 3: 矩阵 $A = (a_{ij})_{n \times n} \in C^{n \times n}$ 的一切特征值都在它的 n 个盖尔圆的并集之中.

证明: 设 $A = (a_{ij})_{n \times n} \in C^{n \times n}$, λ 为 A 的某一个特征值, x 为相应的特征向量, 将 x 写成 $x = [\xi_1, \xi_2, \dots, \xi_n]^T$,

设 $|\xi_{i_0}| = \max |\xi_i|$

由 $Ax = \lambda x$, 考虑 i_0 行

$$\sum_{j=1}^n a_{i_0 j} \xi_j = \lambda \xi_{i_0}$$

$$(\lambda - a_{i_0 i_0}) \xi_{i_0} = \sum_{j=1, j \neq i_0}^n a_{i_0 j} \xi_j \quad (j \neq i_0)$$

$$|\lambda - a_{i_0 i_0}| = \left| \sum_{j=1}^n a_{i_0 j} \frac{\xi_j}{\xi_{i_0}} \right| \leq \sum_{j=1}^n |a_{i_0 j}| \left| \frac{\xi_j}{\xi_{i_0}} \right| \leq R_{i_0}$$

对于 A 的特征值 λ , 一定存在 i_0 ($1 \leq i_0 \leq n$), 使 λ 落在 A 的第 i_0 个盖尔圆中, 对于每个特征值都有相同的结论.

•例题:

例 5.5 估计矩阵 $A = \begin{bmatrix} 1 & 0.1 & 0.2 & 0.3 \\ 0.5 & 3 & 0.1 & 0.2 \\ 1 & 0.3 & -1 & 0.5 \\ 0.2 & -0.3 & -0.1 & -4 \end{bmatrix}$ 的特征

值范围.

解 A 的 4 个盖尔圆为

$$|z - 1| \leq 0.1 + 0.2 + 0.3 = 0.6$$

$$|z - 3| \leq 0.5 + 0.1 + 0.2 = 0.8$$

$$|z + 1| \leq 1 + 0.3 + 0.5 = 1.8$$

$$|z + 4| \leq 0.2 + 0.3 + 0.1 = 0.6$$

画在复平面上如图 5.1 所示.





图 5.1

于是, A 的全部特征值就在这四个盖尔圆并起来的区域之中.

•定理 4: 由矩阵 A 的所有盖尔圆组成的连通部分中任取一个, 如果它是由 k 个盖尔圆构成的, 则在这个连通部分中有且仅有 A 的 k 个特征值 (盖尔圆想重时重复计算, 特征值相同时也重复计算)

证明: 设 $A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix} \in \mathbb{C}^{n \times n},$

令 $B(u) = \begin{bmatrix} a_{11} & ua_{12} & ua_{13} & \cdots & ua_{1n} \\ ua_{21} & a_{22} & ua_{23} & \cdots & ua_{2n} \\ ua_{31} & ua_{32} & a_{33} & \cdots & ua_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ ua_{n1} & ua_{n2} & ua_{n3} & \cdots & a_{nn} \end{bmatrix}$



$$0 \leq u \leq 1, B(0) = \text{diag}[a_{11} \ a_{22} \ \cdots \ a_{nn}], B(1) = A$$

$B(u)$ 的特征多项式是 u 的多项式, 其特征值是 u 的连续函数, 观察 u ($0 \leq u \leq 1$) 变化的过程中 $B(u)$ 特征值的变化, 特征值只能在盖尔圆连通的子集内变动, 而不能跨出连通子集。

由此可见, 由 K 个盖尔圆组成的连通子集恰好包含 K 个特征值。

应该注意到: 连通的这些盖尔圆中, 有些盖尔圆可能包含两个或多个特征值, 而其它盖尔圆中可能无特征值。

•推论:

- (1) 孤立盖尔圆中恰好包含一个特征值
- (2) 实矩阵的孤立盖尔圆恰好包含一个实特征值
- (3) 盖尔圆方法中盖尔圆半径可以按列求和。(因为方阵转置后特征值不变)
- (4) 盖尔圆半径变为 $R_i = \sum_{j=1}^n \frac{\alpha_i}{\alpha_j} |a_{ij}|$, 两个盖尔圆定理仍然成立

5.2 广义特征值与极小极大原理

1. 广义特征值问题

•定义:

设 A 、 B 为 n 阶方阵, 若存在数 λ , 使得方程 $Ax = \lambda Bx$ 存在非零解, 则称 λ 为 A 相对于 B 的广义特征值, x 为 A 相对于 B 的属于广义特征值 λ 的特征向量。

注意: 其是标准特征值问题的推广, 当 $B = I$ (单位矩阵) 时, 广义特征值问题退化为标准特征值问题; 特征向量是非零的; 广义特征值的求解:

$$(A - \lambda B)x = 0 \quad \text{或者} \quad (\lambda B - A)x = 0$$

$$\rightarrow \quad \text{特征方程} \quad \det(A - \lambda B) = 0$$

求得 λ 后代回原方程 $Ax = \lambda Bx$ 可求出 x

•等价表述:

(1) B 正定, B^{-1} 存在 $\rightarrow B^{-1}Ax = \lambda x$, 广义特征值问题化为了标准特征值问题, 但一般来说, $B^{-1}A$ 一般不再是厄米矩阵。

(2) B 厄米, 存在 Cholesky 分解, $B = GG^H$, G 满秩

$$Ax = \lambda GG^Hx \quad \text{令 } G^Hx = y$$

则 $G^{-1}A(G^H)^{-1}y = \lambda y$ 也成为标准特征值问题。

$G^{-1}A(G^H)^{-1}$ 为厄米矩阵, 广义特征值是实数, 可以按大小顺序排列 $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$, 一定存在一组正交归一的特征向量, 即存在 y_1, y_2, \dots, y_n 满足

$$G^{-1}A(G^H)^{-1}y_i = \lambda y_i$$

$$y_i^H y_j = \delta_{ij} = \begin{cases} 1 & i=j \\ 0 & i \neq j \end{cases}$$

还原为 $x_i = (G^H)^{-1}y_i$ ($i=1, 2, \dots, n$), 则

$$y_i^H y_j = (x_i^H G)(G^H x_j) = x_i^H B x_j = \delta_{ij} = \begin{cases} 1 & i=j \\ 0 & i \neq j \end{cases} \quad (\text{带权正交})$$

2. 瑞丽商

A、B 为 n 阶厄米矩阵，且 B 正定，称 $R(x) = \frac{x^H A x}{x^H B x} (x \neq 0)$ 为 A 相对于 B 的广义瑞利商。

x_1, x_2, \dots, x_n 线性无关，所以， $\forall x \in C^n$ ，存在 $a_1, a_2, \dots, a_n \in C$ ，使得 $x = \sum_{i=1}^n a_i x_i$

$$x^H B x = \left(\sum_{i=1}^n a_i x_i \right)^H B \left(\sum_{j=1}^n a_j x_j \right) = \sum_{i,j=1}^n \bar{a}_i a_j x_i^H B x_j = \sum_{i=1}^n |a_i|^2$$

$$x^H A x = \sum_{i,j=1}^n \bar{a}_i a_j x_i^H A x_j = \sum_{i,j=1}^n \bar{a}_i a_j x_i^H \lambda_j B x_j = \sum_{i=1}^n \lambda_i |a_i|^2$$

$$\therefore R(x) = \frac{\sum_{i=1}^n \lambda_i |a_i|^2}{\sum_{i=1}^n |a_i|^2}$$

$$\text{有: } \min_{x \neq 0} R(x) = \lambda_1 \quad \max_{x \neq 0} R(x) = \lambda_n$$

$$\text{证明: } R(x) = \frac{x^H A x}{x^H B x} = \frac{(kx)^H A (kx)}{(kx)^H B (kx)} \quad k \text{ 为非零常数}$$

$$\text{可取 } k = \frac{1}{\|x\|}, \quad \|kx\| = 1$$

$$\therefore R(x) = \frac{x^H A x}{x^H B x} \Big|_{\|x\|=1} \quad (\text{闭区域})$$

当 $x = x_1$ 或 $a_i = 0 (i = 2, 3, \dots, n)$ 时， $R(x) = \lambda_1$

$$\lambda_1 \geq \lambda_1 \quad R(x) \geq \lambda_1 \frac{\sum_{i=1}^n |a_i|^2}{\sum_{i=1}^n |a_i|^2} = \lambda_1$$

$$\therefore \min_{x \neq 0} R(x) = \lambda_1$$

$$\text{另一方面, } \lambda_i \leq \lambda_n \quad R(x) \leq \lambda_n \frac{\sum_{i=1}^n |a_i|^2}{\sum_{i=1}^n |a_i|^2} = \lambda_n$$

$$\therefore \max_{x \neq 0} R(x) = \lambda_n$$

[证毕]

当 $B = I$ 时，标准特征值问题 $Ax = \lambda x \quad (A^H = A)$

$$\begin{cases} \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n \\ x_i^H x_j = \delta_{ij} \end{cases}$$

$$\text{则 } \min_{(x \neq 0)} \frac{x^H A x}{x^H x} = \lambda_1 \quad \max_{(x \neq 0)} \frac{x^H A x}{x^H x} = \lambda_n$$

进一步分析可得

$$\min_{x \neq 0} R(x) \Big|_{a_1=0} = \lambda_2 \quad \max_{x \neq 0} R(x) \Big|_{a_n=0} = \lambda_{n-1}$$

\vdots

$$\min_{x \neq 0} R(x) \Big|_{a_1=a_2=\dots=a_k=0} = \lambda_{k+1} \quad \max_{x \neq 0} R(x) \Big|_{a_n=a_{n-1}=\dots=a_{n-k+1}=0} = \lambda_{n-k+1}$$

•定理 1:

设 $L = \text{span}\{x_r, x_{r+1}, \dots, x_s\}$ ($\lambda_r \leq \lambda_{r+1} \leq \dots \leq \lambda_s$), 则:

$$\min_{\substack{x \neq 0 \\ x \in L}} R(x) = \lambda_r \quad \max_{\substack{x \neq 0 \\ x \in L}} R(x) = \lambda_s$$

•定理 2:

设 V_k 是 C^n 的一个 k 维子空间, 则

$$\max_{V_k \in C^n} \left[\min_{\substack{x \neq 0 \\ x \in V_k}} R(x) \right] = \lambda_{n-k+1} \quad \min_{V_k \in C^n} \left[\max_{\substack{x \neq 0 \\ x \in V_k}} R(x) \right] = \lambda_k$$

以上两式称为广义特征值的极小极大原理。

$B=I$ 时, 标准特征值问题同样存在上述关系;

矩阵奇异值问题: $[\sigma(A)]^2 = \lambda(A^H A)$ (非零)

$$R(x) = \frac{x^H (A^H A) x}{x^H x} = \frac{\|Ax\|_2^2}{\|x\|_2^2}$$

$$\sigma_{n-k+1} = \max_{V_k \in C^n} \left[\min_{\substack{x \neq 0 \\ x \in V_k}} \frac{\|Ax\|_2}{\|x\|_2} \right]$$

$$\sigma_k = \min_{V_k \in C^n} \left[\max_{\substack{x \neq 0 \\ x \in V_k}} \frac{\|Ax\|_2}{\|x\|_2} \right]$$